

UNIVERZITET U BEOGRADU
MATEMATIČKI FAKULTET

Seminarski rad iz predmeta
Istraživanje podataka 2

Tema 27
NBA Database
(klasterovanje)

Autori:
Marija Grekulović, 264/2019
Stepan Ignjatović, 128/2021

Beograd, jul 2026.

Sadržaj

1.	Tekst zadatka	3
2.	Opis podataka	3
2.1.	Skup podataka	3
2.2.	Podaci o tim-sezonama	4
2.3.	Podaci o igračima	4
3.	Opis obrade podataka.....	5
3.1.	Konstrukcija i pretprocesiranje skupa tim-sezona	5
3.2.	Priprema skupa igrača	6
3.3.	Sačuvani fajlovi (ponovljivost)	6
4.	Opis i tumačenje rezultata	7
4.1.	K-Means.....	7
4.2.	Aglomerativno (hijerarhijsko) klasterovanje.....	7
4.3.	Bisecting K-Means	8
4.4.	DBSCAN.....	8
4.5.	HDBSCAN	8
4.6.	OPTICS.....	9
4.7.	CLIQUE.....	10
4.8.	Poređenje modela: svi atributi naspram redukovanih skupova.....	10
4.9.	Klasteri nad redukovanim skupovima atributa (B, C, D)	11
4.10	Aglomerativno klasterovanje igrača.....	12
4.11	Gaussian Mixture Model.....	13
4.12	Spectral Clustering.....	14
4.13	K-Means algoritam	14
4.14	Bisecting K-Means algoritam	15
4.15	DBSCAN.....	16
4.16	Poređenje rezultata	17
5.	Zaključak	18

1. Tekst zadatka

Tema broj 27 seminarskog rada iz predmeta Istraživanje podataka 2 je **NBA Database**. Skup podataka dostupan je na adresi <https://www.kaggle.com/datasets/wyattowalsh/basketball>.

Zadata metoda za studente osnovnih studija smjera Informatika je **klasterovanje**.

Po opštoj strukturi rada iz uputstva, zadatak obuhvata sledeće obavezne korake:

- obavezno izvršiti preprocesiranje podataka;
- podatke obraditi traženom metodom koristeći najmanje 5 algoritama;
- izvršiti analizu dobijenih rezultata i uporediti rešenja za različite algoritme;
- podatke vizuelno prikazati u 2D ili 3D;
- napraviti modele sa svim atributima i sa različitim redukovanim skupovima atributa, pa ih uporediti;
- predati tekstualni deo u PDF formatu (tekst zadatka, opis podataka, opis obrade, opis i tumačenje rezultata), podatke (početnu i preprocesiranu verziju), konstruisane modele i sav materijal potreban za ponavljanje postupka u lokalnom okruženju.

Rad je rađen u paru. Analizu smo podelili na dva nivoa istog skupa: klasterovanje **tim-sezona** na osnovu statistike utakmica i klasterovanje **igrača** na osnovu fizičkih i atletskih merenja sa NBA drafta. Nad tim-sezonama je primenjeno sedam algoritama klasterovanja: K-Means, aglomerativno (hijerarhijsko) klasterovanje, Bisecting K-Means, DBSCAN, HDBSCAN, OPTICS i CLIQUE. Nad igračima su primenjena tri: aglomerativno klasterovanje, Gaussian Mixture Model (GMM) i Spectral Clustering.

2. Opis podataka

2.1. Skup podataka

NBA Database je javno dostupan skup podataka na Kaggle platformi. Pokriva istoriju NBA lige: preko 65.000 utakmica, oko 4.800 igrača i 30 timova. Skup dolazi u dva oblika, kao SQLite baza (nba.sqlite) i kao CSV izvozi istih tabela. Baza ima 16 tabela, a za ovaj rad najvažnije su:

tabela	broj slogova	sadržaj
game	65.698	po jedna vrsta za svaku utakmicu (domaćin i gost)
play_by_play	13.592.899	pojedinačne akcije u utakmicama (nije korišćena)
player	4.815	osnovni podaci o igračima
common_player_info	3.632	prošireni podaci o igračima (pozicija, fizičke mere)
draft_combine_stats	1.633	fizička i atletska merenja sa NBA Draft Combine-a
team	30	aktuelni timovi lige

Tabela 1: Ključne tabelle NBA baze podataka

Podaci se preuzimaju automatski, jednim pozivom biblioteke kagglehub. Oba nivoa analize koriste isti preuzeti direktorijum, pa se ceo postupak može ponoviti na bilo kom računaru.

2.2. Podaci o tim-sezonama

Tabela game ima 65.698 vrsta i 55 kolona. Svaka vrsta opisuje jednu utakmicu, sa statistikom domaćina u kolonama sa sufiksom `_HOME` i gosta u kolonama sa sufiksom `_AWAY`. Pokriven je period od 1946. do 2022. godine. Osnovnih statističkih pokazatelja ima 19: poeni (PTS), asistencije (AST), skokovi (REB, OREB, DREB), blokade (BLK), ukradene lopte (STL), izgubljene lopte (TOV), lične greške (PF), šut iz igre (FGM, FGA, FG_PCT), šut za tri poena (FG3M, FG3A, FG3_PCT), slobodna bacanja (FTM, FTA, FT_PCT) i PLUS_MINUS.

Objekat klasterovanja je **tim-sezona**, odnosno jedan tim u jednoj sezoni. Posle konstrukcije opisane u odeljku 3.1 skup sadrži **1.519 tim-sezona** (45 različitih franšiza kroz istoriju) sa **38 atributa**: po 18 prosečnih pokazatelja po utakmici u napadu i u odbrani (sufiks `_ALLOWED` označava koliko je tim dozvolio protivniku), PLUS_MINUS i procenat pobeda (WIN_PCT).

Kod starih sezona ima dosta nedostajućih vrednosti, jer pojedini pokazatelji tada nisu ni beleženi. Šut za tri poena uveden je tek 1979. godine, a skokovi u napadu i odbrani, ukradene lopte i blokade beleže se od sedamdesetih. Zato, na primer, kolona DREB nedostaje u 440, a FG3A u 366 od 1.519 tim-sezona. Ukupno nedostaje 8.367 vrednosti.

2.3. Podaci o igračima

Za nivo igrača korišćena je tabela `draft_combine_stats` (1.633 sloga), koja sadrži standardizovana fizička i atletska merenja kandidata uoči drafta, spojena sa tabelom `common_player_info` radi pozicije igrača. Ova merenja su pogodna za klasterovanje: rade se po istoj proceduri za sve kandidate, obuhvataju i antropometriju i atletske testove, i ne zavise od kasnije minutaže ili uloge u timu, za razliku od statistike učinka koja meri i kontekst, a ne samo igrača. Svaki igrač opisan je sa **9 atributa** (Tabela 2).

atribut	opis	prosek u skupu
height_wo_shoes	visina bez patika	77,5 in (oko 197 cm)
Weight	telesna težina	214,7 lb (oko 97 kg)
wingspan	raspon ruku	82,4 in (oko 209 cm)
standing_reach	dohvat u stojećem stavu	103,4 in (oko 263 cm)
fat_pct	procenat telesne masti	7,26%
standing_vertical_leap	vertikalni skok iz mesta	29,2 in (oko 74 cm)
max_vertical_leap	vertikalni skok iz zaleta	34,6 in (oko 88 cm)
lane_agility_time	test agilnosti (lane agility)	11,38 s
three_quarter_sprint	sprint na tri četvrtine terena	3,28 s

Tabela 2: Atributi igrača (NBA Draft Combine) i prosečne vrednosti u skupu

Prosečan kandidat ima raspon ruku oko 12 cm veći od sopstvene visine, što je osobina koja se u ligi vrlo izražena. Međutim, ovde ima nedostajućih vrednosti: kandidati ponekad preskaču pojedine testove, pa deo uzoraka nema sva merenja. Skup pokriva draftove iz novijeg perioda lige. Posle čišćenja opisanog u odeljku 3.2 ostaje 1016 igrača.

3. Opis obrade podataka

3.1. Konstrukcija i pretprocesiranje skupa tim-sezona

Filtriranje i izvođenje sezone. Iz identifikatora SEASON_ID izveden je tip sezone (prvi karakter, vrednost 2 označava regularnu sezonu) i godina sezone. Zadržali smo samo utakmice regularne sezone: 65.698 se svodi na 60.192 utakmice, period 1946-2022.

Razdvajanje na perspektivu tima. Svaka utakmica daje dve vrste, jednu iz ugla domaćina i jednu iz ugla gosta. Statistika sopstvenog tima čini ofanzivne atribute, a statistika protivnika dobija sufiks _ALLOWED i opisuje odbranu. Tako se dobija long format sa 120.384 vrsta (tim po utakmici).

Agregacija. Grupisanjem po ključu (TEAM_ID, SEASON_YEAR) izračunali smo proseke po utakmici za sve pokazatelje, procenat pobeda (WIN_PCT) i broj odigranih utakmica (GP). Zadržane su tim-sezone sa bar 20 odigranih utakmica. Dobijeno je 1.519 tim-sezona sa 38 atributa. Ova početna verzija skupa sačuvana je u data/tim_sezone_pocetni.csv.

Nedostajuće vrednosti i standardizacija. Ukupno 8.367 nedostajućih vrednosti popunjeno je medijanom kolone, jer je medijana robusna na ekstremne vrednosti. Zatim su svi atributi standardizovani (StandardScaler: prosek 0, standardna devijacija 1). To je neophodno jer se algoritmi zasnivaju na euklidskom rastojanju, a atributi su na veoma različitim skalama (poeni oko 100, procenti šuta oko 0,45). Preprocesirana verzija sačuvana je u data/tim_sezone_skalirano.csv.

Redukcija dimenzionalnosti i vizuelizacija. Nad standardizovanim podacima primenjen je PCA: za bar 90% varijanse dovoljno je **15 komponenti** od 38. Podaci su prikazani u 2D i 3D pomoću prve dve, odnosno tri glavne komponente, kao i preko t-SNE (perplexity 30). Na graficima se vidi jedan povezan, izdužen oblak tačaka bez jasno razdvojenih grupa, što već nagoveštava da klasterska struktura neće biti oštra.

Skupovi atributa. Za poređenje modela sa svim atributima i sa redukovanim skupovima napravili smo četiri skupa:

- skup A: svi atributi, kompletan opis (38 atributa);
- skup B: ofanzivni, samo pokazatelji sopstvenog napada, bez _ALLOWED i WIN_PCT (19 atributa);
- skup C: efikasnost, ručno izabran manji skup: FG_PCT, FG3_PCT, FT_PCT, FG3A, AST, TOV, OREB, PTS, PTS_ALLOWED, FG_PCT_ALLOWED (10 atributa);
- skup D: PCA, prvih 15 glavnih komponenti koje zajedno objašnjavaju bar 90% varijanse.

3.2. Priprema skupa igrača

Spajanje i čišćenje podataka Merenja sa drafta spojili smo sa pozicijom igrača levim spajanjem tabela po identifikatoru igrača (player_id i person_id). Nedostajuće vrednosti obrađene su u dva koraka: prvo su zadržani samo igrači kojima nedostaju najviše dva od devet atributa, jer redovi sa skoro praznim merenjima ne nose dovoljno informacija i njihovo popunjavanje bi napravilo veštačke profile; zatim su preostale retke praznine popunjene medijanom kolone, iz istog razloga robusnosti kao kod tim-sezona. Od 1 633 redova ostaje 1 016 igrača.

Standardizacija. Svi atributi su standardizovani (StandardScaler). Ovo je obavezno: atributi su na potpuno različitim skalama (težina oko 215 funti, sprint oko 3,3 sekunde), pa bi bez skaliranja euklidsko rastojanje zavisilo praktično samo od težine, a vremenski testovi ne bi uticali skoro uopšte.

Redukcija dimenzionalnosti i korelacije. PCA nad devet standardizovanih atributa pokazuje da prve dve glavne komponente objašnjavaju 72,8% ukupne varijanse, pa je 2D prikaz informativan i svi rezultati su vizuelizovani u ravni (PC1, PC2). Korelaciona matrica objašnjava i zašto: mere veličine (visina, raspon krila, dohvat, težina) su međusobno jako pozitivno korelisane, atletske mere čine drugu grupu (dva skoka, agilnost i sprint), a te dve grupe su međusobno negativno korelisane. Viši i teži igrači u proseku skaču slabije i sporiji su u sprintu, i obrnuto. Podaci, zapravo, imaju jednu glavnu osu – veličina naspram eksplozivnosti – što PCA sažima u prvu komponentu.

3.3. Sačuvani fajlovi (ponovljivost)

Pored početne i preprocesirane verzije podataka, sačuvani su i skup tim-sezona sa dodeljenim oznakama svih algoritama (data/tim_sezone_sa_klasterima.csv) i svi konstruisani modeli u joblib formatu (folder models/): scaler_standard, pca_full, pca_90, kmeans, bisecting_kmeans, agglomerative (matrica spajanja, izabrana veza i oznake), dbscan, hdbscan, optics i clique (modeli, parametri i oznake). U fajlu tim_sezone_sa_klasterima.csv su i kolone cluster_hdbscan, cluster_optics i cluster_clique. Ceo postupak se ponavlja pokretanjem priloženog Jupyter notebook-a, a podaci se automatski preuzimaju sa Kaggle-a.

Za deo zadatka koji se bavi skupom igrača sačuvani su modeli u folderu models ako i tabela df_clean.csv.

4. Opis i tumačenje rezultata

Prvo su dati rezultati klasterovanja tim-sezona (odeljci 4.1 do 4.9), a zatim rezultati klasterovanja igrača (odeljci 4.10 do 4.13).

4.1. K-Means

Broj klastera birali smo metodom lakta (inercija), silueta koeficijentom i Calinski-Harabasz (CH) indeksom, za K od 2 do 10, nad skupom A. I silueta i CH indeks predlažu **K = 2**. Finalni model (K-Means++ inicijalizacija, n_init 50) daje klastere veličina 921 i 598, sa siluetom 0,1963, CH 332,0 i Davies-Bouldin (DB) indeksom 1,8892.

Kada se centroidi vrte u originalnu skalu, interpretacija je jasna. Podela ne razdvaja dobre i loše timove, WIN_PCT je skoro isti u oba klastera (0,51 i 0,49). Podela razdvaja **ere košarke po stilu igre**:

klaster	veličina	PTS	PTS_ALL O WED	FG3A	FG3_PC T	AST	TOV	WIN_PC T
0 (moderna era)	921	99,2	99,0	20,2	0,35	22,2	14,6	0,51
1 (klasična era)	598	107,8	108,1	10,2	0,31	24,2	16,1	0,49

Tabela 3: Profili K-Means klastera (prosečne vrednosti u originalnim jedinicama)

Klaster 0 okuplja tim-sezone sa duplo više pokušaja za tri poena (20,2 naspram 10,2 po utakmici) i nižim ukupnim skorom. To je profil moderne košarke oslonjene na šut za tri (primeri: Golden State Warriors 2015. i 2016, Dallas Mavericks 2006). Klaster 1 okuplja starije, brže ere sa više poena i asistencija, a malo šuteva za tri (primeri: Los Angeles Lakers 1971, Boston Celtics 1959. i 1985). Dominantan signal u podacima je znači istorijska evolucija stila igre, a ne kvalitet tima.

4.2. Aglomerativno (hijerarhijsko) klasterovanje

Dendrogram i broj klastera. Nad skupom A napravili smo matricu spajanja (ward veza). Metod najvećeg vertikalnog skoka u dendrogramu predlaže **K = 3** (skok 37,7, naspram 27,1 za K = 2). Hijerarhija znači vidi i nešto finiju podelu od K-Means-a; treća grupa odgovara najstarijim sezonama. Radi poštenog poređenja sa ostalim algoritmima u nastavku koristimo K = 2, a podela na tri klastera prikazana je u notebook-u.

Poređenje veza i degenerisane podele. Za K = 2 uporedili smo četiri veze. Rezultat pokazuje zašto silueta ume da prevari:

veza	silueta	CH	DB	najmanji klaster	degenerisano
single	0,8111	47,5	0,1320	1	da
complete	0,8111	47,5	0,1320	1	da
average	0,8111	47,5	0,1320	1	da
ward	0,1857	306,0	1,9395	558	ne

Tabela 4: Poređenje veza aglomerativnog klasterovanja (K = 2)

Veze single, complete i average izdvajaju jednu jedinu tačku u poseban klaster (efekat ulančavanja), a preostalih 1.518 tim-sezona ostave zajedno. Takva podela nema smisla, ali dobija visoku siluetu (0,81): za skoro sve tačke najbliži drugi klaster je jedna

veoma udaljena tačka, pa razlika rastojanja izgleda odlično. Zato smo uveli proveru degenerisanih podela: najmanji klaster mora imati bar $\max(3; 2\% \text{ tačaka}) = 30$ tačaka, a veza se bira po silueti samo među nedegenerisanim podelama. Izabrana je **ward** veza. Njena niža silueta (0,1857) je poštena ocena stvarne, meke strukture podataka. Slaganje ward podele sa K-Means podelom je visoko (prilagođeni Randov indeks $ARI = 0,776$).

4.3. Bisecting K-Means

Bisecting K-Means je divizivni (top-down) hijerarhijski pristup: kreće od svih podataka u jednom klasteru i uzastopno deli najgori klaster običnim K-Means-om sa $K = 2$. Za $K = 2$ prva podela je ujedno i konačna, pa je rezultat identičan K-Means-u: iste veličine klastera (921 i 598), ista silueta (0,1963) i $ARI = 1,0$ u odnosu na K-Means. To je očekivano i služi kao provera doslednosti. Razlike između ova dva algoritma dolaze do izražaja tek za veće K .

4.4. DBSCAN

DBSCAN grupiše tačke gustih oblasti i ne zahteva unapred zadat broj klastera, a retke tačke označava kao šum (oznaka -1). Parametre ϵ (poluprečnik okoline) i $\min_samples$ (minimalan broj suseda za jezgro) birali smo grid search pretragom: ϵ od 0,3 do 3,0 sa korakom 0,15 (19 vrednosti) i $\min_samples$ od 3 do 10, ukupno 152 kombinacije. Zbog osetljivosti metoda zasnovanih na gustini na visoku dimenzionalnost, algoritam je primenjen nad 2D PCA projekcijom. Validnim smo smatrali podele sa bar 2 klastera i najviše 30% šuma (57 od 152 kombinacije). Među njima je po silueti, računatoj bez šuma, najbolja kombinacija **$\epsilon = 1,5$, $\min_samples = 3$** .

Rezultat: 2 klastera veličina **1.508 i 4**, uz 7 tačaka šuma (0,5%). Silueta bez šuma iznosi 0,6533. Iako je to nominalno najviša vrednost u celom radu, treba je tumačiti oprezno. DBSCAN je praktično sve tim-sezone smestio u jedan veliki gust klaster, a drugi klaster čine samo četiri međusobno bliske, udaljene tačke (ekstremne rane sezone), plus nekoliko izolovanih elemenata van granica. Visoka silueta je posledica iste pojave kao kod single veze u odeljku 4.2, male i daleke grupe, a ne stvarne opšte strukture. Pravi nalaz DBSCAN-a je da **tim-sezone čine jedan gust kontinuum bez gustinski razdvojenih grupa**. To se slaže sa umerenim siluetama particionih metoda: podela na dve ere postoji, ali kao postepen prelaz, ne kao praznina u prostoru.

4.5. HDBSCAN

HDBSCAN (Hierarchical DBSCAN) je hijerarhijska nadogradnja DBSCAN-a. Umesto jedne fiksne vrednosti ϵ , algoritam gradi hijerarhiju klastera za sve vrednosti ϵ , pa meri **stabilnost** svakog klastera: gust klaster preživljava dugo dok povećavamo ϵ , a redak kratko. Zadržavaju se samo najstabilniji klasteri, a sve ostale tačke dobijaju oznaku šuma. Zato HDBSCAN ne zahteva ϵ i radi i kada klasteri imaju različite gustine.

Ostaju dva parametra. $\min_cluster_size$ određuje koliko klaster mora biti velik da bi se uopšte računao kao klaster (da li je grupa dovoljno velika). $\min_samples$ određuje koliko gust mora biti (da li je grupa dovoljno gusta); ako se ne zada, podrazumevano je jednak $\min_cluster_size$, što smo i koristili. Kao i DBSCAN, algoritam smo primenili nad 2D PCA projekcijom.

Vrednost $\min_cluster_size$ birali smo malom pretragom po vrednostima 10, 20, 30, 50 i 100, sa istim kriterijumom validnosti kao kod DBSCAN-a: bar 2 klastera i najviše 30% šuma (Tabela 5). Nijedna vrednost ne ispunjava prag šuma, pa smo uzeli onu sa najmanje šuma, **$\min_cluster_size = 50$** .

min_cluster_size	klastera	šum %	silueta (bez šuma)
10	8	54,3	0,3654
20	3	54,2	0,6125
30	3	53,5	0,6094
50	2	35,2	0,5242
100	2	72,4	0,6824

Tabela 5: Pretraga po min_cluster_size za HDBSCAN (2D PCA projekcija)

Finalni model daje 2 klastera veličina **904 i 81**, uz 534 tačke šuma (35,2%). Silueta bez šuma iznosi 0,5242. Slika je ista kao kod DBSCAN-a, samo strože isečena: HDBSCAN zadržava samo stabilno jezgro oblaka i jednu manju gustu grupu na njegovom obodu, a razređene ivice kontinuuma proglašava šumom. Zato je udeo šuma veliki. Vredi primetiti i da najvišu siluetu u pretrazi (0,6824) daje min_cluster_size = 100 uz čak 72,4% šuma: što se više tačaka izbaci, preostalo izgleda kompaktnije. Siluetu zato treba čitati zajedno sa udelom šuma, a ne samu za sebe.

HDBSCAN daje i verovatnoću pripadnosti klasteru (probabilities_) za tačke koje nisu šum. Verovatnoća blizu 1 znači da je tačka duboko u svom klasteru, a manje vrednosti da je blizu ivice. U notebook-u je prikazano prvih deset tačaka; njihove verovatnoće se kreću od 0,79 do 1,00.

4.6. OPTICS

OPTICS (Ordering Points To Identify the Clustering Structure) rešava problem koji DBSCAN ima kada klasteri imaju različite gustine: jedan eps ne može da odgovara svima. Umesto da fiksira eps, OPTICS tačke ređa u poseban redosled (ordering) iz koga se klasteri različitih gustina mogu naknadno izvući.

Dva ključna pojma. **core_distance** tačke je udaljenost do njenog k-tog najbližeg suseda, gde je k = min_samples: u gustom regionu je mala, u redem velika. **reachability_distance** tačke p u odnosu na već obrađenu tačku o je veća od dve vrednosti, core_distance tačke o i običnog rastojanja d(o, p). Ako je o u gustom regionu, reachability je praktično obično rastojanje; ako je o u redem, reachability raste. Algoritam kreće od proizvoljne tačke i za sledeću uvek uzima onu sa najmanjim reachability, pa gustinske oblasti obilazi jednu po jednu.

Rezultat se čita sa reachability plot: na x-osi je redosled obrade, na y-osi reachability. Niske vrednosti znače guste regione, unutrašnjost klastera. Skokovi označavaju prelaze između klastera ili šum. Naš plot (u notebook-u) ima jednu dugačku nisku dolinu i skokove tek na obodima, dakle jedan veliki gust region, bez dubokih useka koji bi delili više klastera.

Klasteri se iz ordering-a izvlače na dva načina i oba smo probali. Prvi je **DBSCAN ekstrakcija**: izabere se eps, pa sve povezane tačke sa reachability manjim od eps čine klaster. Sa eps = 1,5, vrednošću koju je grid search našao za DBSCAN, dobija se praktično jedan klaster sa 1.506 tačaka i 13 tačaka šuma (0,9%), što se poklapa sa nalazom samog DBSCAN-a. Drugi je **Xi metoda**: automatski se traže nagla povećanja reachability i ordering se seče tamo gde gustina naglo opada (xi = 0,05, uz min_cluster_size = 5% tačaka). Xi izdvaja samo dva najgušća džepa, klastera od 97 i 88 tačaka na obodima oblaka, a čak 1.334 tačke (87,8%) proglašava šumom. Silueta bez šuma je 0,7837, nominalno najviša u celom radu, ali iz već poznatog razloga: računa se samo nad dve male kompaktne grupe, pa je ovo isti efekat kao u odeljcima 4.2 i 4.4, a ne stvarna struktura.

OPTICS, dakle, potvrđuje istu sliku iz dva ugla: kada se gleda kao DBSCAN, sve je jedan gust

klaster; kada se traže samo najgušća mesta, ostanu dva mala džepa.

4.7. CLIQUE

CLIQUE je algoritam zasnovan na mreži (grid-based). Prostor se podeli na mrežu ćelija, po `amount_intervals` jednakih intervala duž svake dimenzije. Ćelija je **gusta** ako sadrži bar `density_threshold` tačaka. Klaster je skup povezanih susednih gustih ćelija, a tačke koje ne upadaju ni u jednu gustu ćeliju su elementi van granica. Koristili smo implementaciju iz biblioteke `pyclustering`, istu kao na vežbama, uz njen prikaz mreže (`clique_visualizer`).

Na vežbama je nad Iris skupom (150 tačaka) korišćeno 5 intervala po dimenziji. Naš skup ima desetostruko više tačaka, pa smo uzeli gušću mrežu, 15 intervala po dimenziji, uz prag gustine 3. Algoritam je primenjen nad istom 2D PCA projekcijom kao ostale metode ove grupe.

Rezultat: 3 klastera veličina **1.454, 5 i 4**, uz 56 tačaka van granica (3,7%); silueta bez šuma je 0,2862. Mreža gustih ćelija (prikazana u notebook-u) pokazuje jedan veliki povezan blok preko sredine oblaka i dve sićušne guste ćelije na obodu. I CLIQUE, dakle, vidi isto što i DBSCAN, HDBSCAN i OPTICS: jedan povezan gust region i poneki mali džep na ivici.

Tabela 6 sumira sve četiri metode ove grupe. Razlikuju se po tome koliko razređenih ivica proglase šumom, od 0,5% kod DBSCAN-a do 87,8% kod OPTICS Xi ekstrakcije, ali je suština kod svih ista: tim-sezone nemaju gustinski razdvojene velike grupe. Siluete ovih metoda ne treba porediti direktno sa particionim algoritmima, jer se računaju samo nad zadržanim tačkama, a najviše vrednosti dobijaju upravo podele koje najviše tačaka izbace.

algoritam	klastera	veličine	šum	silueta (bez šuma)
DBSCAN (eps=1,5, min_samples=3)	2	1.508 / 4	7 (0,5%)	0,6533
HDBSCAN (min_cluster_size=50)	2	904 / 81	534 (35,2%)	0,5242
OPTICS (Xi ekstrakcija)	2	97 / 88	1.334 (87,8%)	0,7837
CLIQUE (15 intervala, prag 3)	3	1.454 / 5 / 4	56 (3,7%)	0,2862

Tabela 6: Rezime algoritama zasnovanih na gustini i mreži (svi nad 2D PCA projekcijom)

4.8. Poređenje modela: svi atributi naspram redukovanih skupova

Tri algoritma sa zadatim brojem klastera (K-Means, aglomerativno-ward i Bisecting, $K = 2$) uporedili smo nad sva četiri skupa atributa. DBSCAN, HDBSCAN, OPTICS i CLIQUE nisu u ovoj tabeli jer broj klastera određuju sami; njihovi rezultati su u odeljcima 4.4 do 4.7.

skup atributa	algoritam	silueta	CH	DB
A: svi atributi (38)	K-Means	0,1963	332,0	1,8892
	Aglo-ward	0,1857	306,0	1,9395
	Bisecting	0,1963	332,0	1,8892
B: ofanzivni (19)	K-Means	0,1900	328,8	1,9071
	Aglo-ward	0,1614	284,2	2,0662
	Bisecting	0,1900	328,8	1,9071
C: efikasnost (10)	K-Means	0,2999	358,8	1,4154
	Aglo-ward	0,2569	326,2	1,5959
	Bisecting	0,3005	358,8	1,4089
D: PCA 90% (15)	K-Means	0,2116	374,2	1,7665
	Aglo-ward	0,1887	335,2	1,8571
	Bisecting	0,2116	374,2	1,7665

Tabela 7: Poređenje algoritama po skupovima atributa ($K = 2$); veća silueta i CH su bolje, manji DB je bolji

Zaključci poređenja: (1) najbolje rezultate po sve tri metrike daje **skup C**, ručno izabranih 10 pokazatelja efikasnosti (najbolja silueta 0,3005 za Bisecting, najniži DB 1,4089). Pažljiva redukcija atributa znači daje jasnije razdvajanje nego svih 38 atributa, koji unose šum i redundansu kroz visoko korelisane kolone. (2) I PCA redukcija (skup D) poboljšava rezultate u odnosu na pun skup, a K-Means i Bisecting na njemu imaju najviši CH (374,2). (3) Čisto ofanzivni skup B je najslabiji, informacija o odbrani očigledno doprinosi strukturi. (4) K-Means i Bisecting su dosledno jednaki, kao u odeljku 4.3, dok je ward aglomerativno na svakom skupu neznatno slabije od njih.

4.9. Klasteri nad redukovanim skupovima atributa (B, C, D)

Na kraju smo proverili da li se slika menja kada se promeni skup atributa. Za svaki redukovani skup prikazali smo u notebook-u klastere svih sedam algoritama, u 2D projekciji tog skupa: B i C se projektuju sopstvenim PCA, a D već jeste PCA pa koristimo prve dve komponente. Algoritmi sa zadatim brojem klastera treniraju se nad svim atributima skupa, a algoritmi zasnovani na gustini i mreži nad 2D projekcijom, isto kao u svojim odeljcima. DBSCAN parametre za svaki skup ponovo bira isti grid search, jer projekcije različitih skupova imaju različite razmere.

Rezultati su dosledni. Podela na dve ere vidi se na svakom skupu, najčistije na skupu C (siluete su u Tabeli 7). Metode zasnovane na gustini i mreži na svakom skupu ponavljaju obrazac sa skupa A: jedan veliki gust region, male guste grupe na obodima i deo tačaka proglašen šumom. Promena skupa atributa menja oštrinu podele, ali ne i njenu suštinu, pa je zaključak o dve ere i mekom kontinuumu stabilan na izbor atributa.

4.10 Aglomerativno klasterovanje igrača

Nad standardizovanim atributima 1 016 igrača prvo smo primenili aglomerativno klasterovanje sa **ward** vezom. Izbor veze sledi iz analize u odeljku 4.2, gde se ward pokazala jedinom otpornom na degenerisane podele. Napravljen je dendrogram sa označenim predloženim rezom, a broj klastera biran je po najvećoj silueti za k od 2 do 9. Silueta je ubedljivo najveća za $k = 2$ (0,2533) i monotono opada sa porastom k (Tabela 8). U podacima je dominantna jedna binarna podela, a svako dalje usitnjavanje seče prirodne grupe.

k	Agglomerativno (ward)	GMM	Spectral (rbf)
2	0,2533	0,2425	0,3127
3	0,1890	0,1779	0,2395
4	0,1483	0,1096	0,1810
5	0,1175	0,0715	0,1401
6	0,1148	0,0686	0,1110
7	0,1142	0,0719	0,1005
8	0,0990	0,0369	0,1026
9	0,0909	0,0472	0,0916

Finalni model ($k = 2$, ward) deli igrače na klastere veličina **560 i 456**. Profil klastera, prosečne vrednosti atributa po klasteru prikazane u notebook-u toplotnom mapom, pokazuje da jedan klaster čine viši, teži i duži igrači (veća visina, raspon ruku, dohvat i procenat masti) sa slabijim skokom i sporijim vremenima, a drugi niži, lakši i eksplozivniji igrači. Reč je o podeli na **unutrašnje** (krilni centri i centri) i **spoljne** igrače (plejmejkeri, bekovi i krilni igrači). Detaljno tumačenje, zajedničko za sva tri algoritma, dato je u odeljku 4.13.

4.11 Gaussian Mixture Model

GMM pretpostavlja da su podaci generisani mešavinom k višedimenzionalnih Gausovih raspodela: svaki klaster je jedna raspodela, opisana svojim centrom i kovarijacionom matricom. Kovarijaciona matrica dozvoljava klasteru elipsoidan oblik, sopstvenu veličinu i orijentaciju, za razliku od K-Means-a koji implicitno pretpostavlja sferne klastere jednakih širina. Parametri se uče EM algoritmom (Expectation-Maximization): u E-koraku se pri tekućim parametrima za svaku tačku izračunaju verovatnoće pripadnosti komponentama, u M-koraku se parametri ponovo ocene na osnovu tih verovatnoća, i koraci se smenjuju do konvergencije. Najvažnija praktična razlika u odnosu na prethodne algoritme je **meko klasterovanje**: svaka tačka dobija raspodelu verovatnoća pripadnosti, a ne samo jednu oznaku.

Broj komponenti biran je istim postupkom (Tabela 9): najbolja silueta je za $n = 2$ (0,2425), takođe uz monoton pad. Finalni model deli igrače na komponente veličina **650 i 366**; manja komponenta (366 igrača) odgovara grupi unutrašnjih igrača. Granica između grupa povučena je nešto drugačije nego kod aglomerativnog modela, jer se elipsoidne komponente prilagođavaju izduženom obliku oblaka drugačije od hijerarhijskog reza. Tabela 9 prikazuje verovatnoće pripadnosti za nekoliko igrača iz skupa:

igrač	P(unutrašnji)	P(spoljni)	dodela
Adam Allenspach (centar)	1,000	0,000	unutrašnji
Shane Battier (krilo)	0,833	0,167	unutrašnji
Ruben Boumtje-Boumtje (centar)	0,698	0,302	unutrašnji
Gilbert Arenas (plejmejker)	0,009	0,991	spoljni
Charlie Bell (bek)	0,008	0,992	spoljni

Tabela 9: Primeri verovatnoća pripadnosti klasterima (GMM, meko klasterovanje; vrednosti su zaokružene na tri decimale)

Za većinu igrača pripadnost je gotovo izvesna: centar sa verovatnoćom skoro 1,000, plejmejker sa 0,991. Igrači na granici dva fizička profila dobili su umerene verovatnoće, krilo Shane Battier (0,833 : 0,167) i Ruben Boumtje-Boumtje (0,698 : 0,302). Tu meko klasterovanje daje informaciju koju tvrdi algoritmi nemaju: koliko je dodela pouzdana. Za igrače između pozicija tvrda oznaka prikriva neizvesnost, a GMM je izmeri.

4.12 Spectral Clustering

Spectral Clustering na podatke gleda kroz graf sličnosti: svaka tačka je čvor, a težina grane meri sličnost dve tačke, ovde preko Gausovog (RBF) kernela kod koga sličnost eksponencijalno opada sa kvadratom rastojanja. Nad grafom se izračuna Laplasijan, a njegovi svojstveni vektori daju novu, spektralnu reprezentaciju podataka u kojoj se grupe interno jako povezanih čvorova prirodno razdvajaju. U tom prostoru se zatim primeni obično K-Means klasterovanje. Prednost pristupa je što ne pretpostavlja konveksan (loptast) oblik klastera: traži grupe koje su iznutra gusto povezane, a međusobno slabo, pa može otkriti strukture koje particionim metodama promaknu.

Broj klastera je opet biran po silueti (Tabela 8). I ovde je ubedljivo najbolja podela na $k = 2$, sa siluetom **0,3127**, najvišom među sva tri algoritma nad igračima. Podela je ipak izrazito nejednaka: **814 naspram 202** igrača. Umesto ravnomernog reza duž ose veličine, spektralni pristup je izdvojio kompaktnu, interno vrlo sličnu grupu igrača najizraženijeg profila, a sve ostale ostavio zajedno. Deo prednosti u silueti dolazi od kompaktnosti male grupe, slično opreznim tumačenjima iz odeljaka 4.2 i 4.4. Ovde podela ipak nije degenerisana: manji klaster ima 202 igrača, punih 20% skupa, a profil klastera pokazuje isti smer razdvajanja kao kod ostalih algoritama.

4.13 K-Means algoritam

K-Means predstavlja jedan od najčešće korišćenih algoritama za grupisanje podataka u nenadgledanom učenju. Cilj algoritma je da podeli skup podataka na unapred definisan broj klastera (k) tako da objekti unutar istog klastera budu što sličniji, dok se objekti iz različitih klastera međusobno razlikuju. Algoritam funkcioniše iterativno tako što određuje centre klastera (centroide), dodeljuje svaki objekat najbližem centroidu i zatim ažurira položaje centroida sve dok se ne postigne konvergencija.

U ovom radu K-Means algoritam je primenjen nad prethodno standardizovanim podacima (`X_scaled`), čime je obezbeđeno da sve promenljive imaju jednak uticaj na formiranje klastera. Kako K-Means koristi euklidsko rastojanje, standardizacija podataka predstavlja važan korak u pripremi skupa podataka.

Optimalan broj klastera nije unapred poznat, pa je izvršeno testiranje vrednosti parametra k u opsegu od 2 do 9. Za svaku vrednost parametra kreiran je poseban K-Means model, nakon čega je izračunat **Silhouette koeficijent**, koji predstavlja meru kvaliteta klasterizacije. Veće vrednosti Silhouette koeficijenta ukazuju na bolje razdvojene i kompaktnije klastere.

Optimalan broj klastera određen je izborom modela koji ostvaruje najveću vrednost Silhouette koeficijenta. Nakon toga je kreiran konačni K-Means model sa izabranim brojem klastera, pri čemu je korišćen parametar `random_state = 42` kako bi rezultati bili reproduktivni.

Dobijeni rezultat :

- broj klastera: $k = 2$
- Silhouette koeficijent: **0,2971**

Može se uočiti da su formirana dva klastera približno slične veličine, pri čemu prvi klaster sadrži **463** objekta, dok drugi obuhvata **553** objekta.

Vrednost Silhouette koeficijenta od **0,2971** ukazuje na **umeren kvalitet klasterizacije**. Ovakva vrednost sugerise da između klastera postoji određeni stepen razdvajanja, ali granice između njih

nisu potpuno jasno definisane. Drugim rečima, objekti unutar klastera pokazuju određenu međusobnu sličnost, ali postoji i preklapanje između pojedinih grupa.

Na osnovu dobijenih rezultata može se zaključiti da K-Means algoritam identifikuje prirodnu podelu podataka na dva klastera, pri čemu ostvaruje zadovoljavajući, ali ne i izrazito visok kvalitet grupisanja.

4.14 Bisecting K-Means algoritam

Bisecting K-Means predstavlja hijerarhijsku varijantu K-Means algoritma koja kombinuje principe deljivog (divisive) hijerarhijskog grupisanja i klasičnog K-Means algoritma. Za razliku od standardnog K-Means algoritma, koji istovremeno formira unapred definisan broj klastera, Bisecting K-Means započinje sa jednim klasterom koji sadrži sve objekte, a zatim ga iterativno deli na dva podklastera primenom K-Means algoritma. Postupak se ponavlja sve dok se ne dobije željeni broj klastera.

U ovom radu algoritam je primenjen nad standardizovanim skupom podataka (`x_scaled`).

Kako optimalan broj klastera nije bio unapred poznat, izvršeno je testiranje vrednosti parametra k u opsegu od 2 do 9. Za svaku vrednost broja klastera kreiran je poseban Bisecting K-Means model, nakon čega je izračunat **Silhouette koeficijent** kao mera kvaliteta klasterizacije. Optimalan broj klastera izabran je na osnovu najveće ostvarene vrednosti ovog koeficijenta.

Nakon određivanja optimalnog broja klastera kreiran je konačni Bisecting K-Means model sa parametrom `random_state = 42`, čime je obezbeđena reproduktivnost rezultata.

Dobijeni rezultati su sledeći:

- broj klastera: **$k = 2$**
- Silhouette koeficijent: **0,2974**

Rezultati pokazuju da su formirana dva klastera približno jednake veličine, pri čemu prvi klaster sadrži **459** objekata, dok drugi obuhvata **557** objekata.

Vrednost Silhouette koeficijenta od **0,2974** ukazuje na **umeren kvalitet klasterizacije**, odnosno na postojanje određene razdvojenosti između klastera, ali bez izrazito jasnih granica. Dobijena vrednost je vrlo bliska rezultatu ostvarenom primenom standardnog K-Means algoritma, što ukazuje da oba pristupa prepoznaju sličnu strukturu u analiziranim podacima.

4.15 DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) predstavlja algoritam za grupisanje podataka zasnovan na gustini. Ne zahteva unapred definisanje broja klastera, već samostalno identifikuje grupe objekata na osnovu njihove međusobne gustine. Pored toga, algoritam može da prepozna objekte koji ne pripadaju nijednom klasteru i označi ih kao **šum (oulier)**.

DBSCAN koristi dva osnovna parametra:

- **eps** – maksimalno rastojanje između dva objekta da bi se smatrali susedima;
- **min_samples** – minimalan broj susednih objekata potreban da bi se formirao gust region, odnosno klaster.

U ovom radu korišćen je parametar **min_samples = 5**, dok je vrednost parametra **eps** određivana eksperimentalno. Testirane su vrednosti u opsegu od **0,5 do 2,9**, sa korakom od **0,2**. Za svaku vrednost parametra **eps** određivan je broj pronađenih klastera, broj objekata označenih kao šum i, kada su postojala najmanje dva klastera, izračunavan je **Silhouette koeficijent**.

Rezultati ispitivanja pokazali su da za manje vrednosti parametra **eps** (0,5 i 0,7) algoritam nije uspeo da formira nijedan klaster, već je sve objekte klasifikovao kao šum. Povećanjem vrednosti parametra na **0,9** algoritam je pronašao **7 klastera**, pri čemu je ostvarena najveća vrednost Silhouette koeficijenta od **0,1762**. Za veće vrednosti parametra **eps** broj klastera se smanjivao, dok su pri vrednostima od **1,3** i većim svi objekti praktično bili objedinjeni u jedan klaster, zbog čega Silhouette koeficijent nije mogao biti izračunat.

Najbolji rezultat ostvaren je za sledeće parametre:

- **eps = 0,9**
- **min_samples = 5**
- broj klastera: **7**
- Silhouette koeficijent: **0,1762**
- broj objekata označenih kao šum: **944**

Rezultati pokazuju da je DBSCAN označio čak **92,9%** objekata kao šum, dok je samo mali broj objekata raspoređen u sedam klastera. Ovakav ishod ukazuje da analizirani skup podataka ne poseduje jasno izražene regione velike gustine koji bi omogućili efikasno grupisanje primenom DBSCAN algoritma.

Pored toga, ostvarena vrednost **Silhouette koeficijenta od 0,1762** znatno je niža u odnosu na rezultate dobijene drugim algoritmima. To ukazuje da su klasteri formirani pomoću DBSCAN algoritma manje kompaktni i slabije međusobno razdvojeni.

Na osnovu dobijenih rezultata može se zaključiti da DBSCAN nije dao zadovoljavajuće rezultate na analiziranom skupu podataka. Veliki broj objekata klasifikovan je kao šum, dok je kvalitet formiranih klastera bio niži u odnosu na ostale algoritme.

4.16 Poređenje rezultata

Tri algoritma uporedili smo nad istim standardizovanim atributima. Rezime je u Tabeli 10, a uporedni 2D prikazi sve tri podele u ravni (PC1, PC2) dati su u notebook-u.

algoritam	klastera	veliĉine	silueta	tip
Aglomerativno (ward)	2	560 / 456	0,2533	hijerarhijski
GMM	2	650 / 366	0,2425	statistiĉki model
Spectral Clustering (rbf)	2	814 / 202	0,3127	graf sliĉnosti
K-Means	2	553 / 463	0,2971	centroidni
Bisecting K-Means	2	557/495	0,2974	hijerarhijski
DBSCAN	7	28 / 12 / 10 / 9 / 5 / 4 / 4 (+ 944 űum)	0,1762	gustinski

Tabela 10: Poređenje algoritama nad skupom igrača

Najvažniji nalaz je saglasnost algoritama u suštini podele. Sva tri, iz potpuno razliĉitih principa (hijerarhijsko spajanje, statistiĉka meűavina, graf sliĉnosti), nezavisno biraju $k = 2$ i dele igraĉe duű iste ose, **ose veliĉine i atletskog profila**. Jedan pol ĉine unutraűnji igraĉi: viűi, teűi, duűih ruku i veĉeg dohvata, sa neűto viűim procentom masti, slabijim vertikalnim skokom i sporijom agilnoűću i sprintom. Drugi pol ĉine spoljni igraĉi: niűi i lakűi, ali eksplozivniji, sa boljim skokom i brűim vremenima. To odgovara koűarkaűskoj intuiciji o kontinuumu bek-centar i strukturi koju je nagovestila korelaciona analiza u odeljku 3.2.

Algoritmi se razlikuju u tome gde povlaĉe granicu na tom kontinuumu: aglomerativni deli skup najpravnomernije (560 i 456), GMM daje neűto nejednakiju podelu (650 i 366), a Spectral izdvaja najkompaktniju podgrupu (814 i 202) i time postiűe najviűu siluetu. Umerene vrednosti silueta (oko 0,24 do 0,31) govore da granica izmeĊu profila nije oűtra. Fiziĉke mere igrača ĉine kontinuum sa dva pola, a ne dva ostrva, űto je nalaz istog karaktera kao meka struktura tim-sezona i u skladu je sa savremenim trendom pozicijske fluidnosti u ligi. Dodatnu vrednost daje GMM: njegove verovatnoĉe pripadnosti mere upravo tu mekoću granice i izdvajaju krilne igraĉe kao prelazni tip izmeĊu dva pola.

Rezultati dobijeni primenom **K-Means**, **Bisecting K-Means** i **DBSCAN** algoritama dodatno potvrĊuju prethodne zakljuĉke. K-Means i Bisecting K-Means, iako zasnovani na razliĉitim pristupima grupisanju, nezavisno odreĊuju **optimalan broj klastera $k = 2$** i ostvaruju gotovo identične vrednosti Silhouette koeficijenta (**0,2971** i **0,2974**). Obe metode dele igraĉe duű iste osnovne dimenzije fiziĉkih karakteristika, pri ĉemu se formiraju dve grupe pribliűno jednake veliĉine. Ovi rezultati predstavljaju dodatnu potvrdu da u analiziranim podacima postoji stabilna i prirodna podela na dva dominantna fiziĉka profila.

Za razliku od njih, **DBSCAN** ne zahteva unapred definisan broj klastera, veĉ ih odreĊuje na osnovu gustine podataka. Najbolji rezultat postignut je za parametar **eps = 0,9**, pri ĉemu je algoritam identifikovao **7 manjih klastera**, ali je ĉak **944 od ukupno 1016 igrača (92,9%)** oznaĉio kao űum. Ostvareni Silhouette koeficijent (**0,1762**) znatno je niűi od vrednosti dobijenih ostalim algoritmima, űto ukazuje da analizirani skup podataka ne sadrűi jasno izraűene regione velike gustine koji bi pogodovali primeni DBSCAN algoritma.

Posmatrajuĉi sve primenjene metode zajedno, moűe se zakljuĉiti da algoritmi zasnovani na centroidima (**K-Means** i **Bisecting K-Means**), hijerarhijski pristup (**Agglomerative Clustering**), statistiĉki model (**GMM**) i grafovski pristup (**Spectral Clustering**) dosledno ukazuju na postojanje dve dominantne grupe igrača, dok se jedino **DBSCAN** znaĉajnije razlikuje zbog svoje osetljivosti na gustinu raspodele podataka. Ovakva saglasnost veĉine algoritama dodatno potvrĊuje da fiziĉke karakteristike NBA igrača prirodno formiraju kontinuum sa dva dominantna pola, dok odsustvo jasno odvojenih gustih regiona objaűnjava slabije performanse DBSCAN algoritma.

5. Zaključak

Skup NBA podataka analizirali smo klasterovanjem na dva nivoa, nad tim-sezonama smo primenili sedam algoritama (K-Means, aglomerativno hijerarhijsko klasterovanje, Bisecting K-Means, DBSCAN, HDBSCAN, OPTICS i CLIQUE), a nad igračima tri (aglomerativno klasterovanje, GMM i Spectral Clustering). Najvažniji nalazi:

- Tim-sezone se najprirodnije dele na dve ere košarke, modernu (duplo više šuteva za tri, niži skor) i klasičnu (brža igra, više poena), a ne na dobre i loše timove: procenat pobeda je u oba klastera oko 0,5. Dendrogram nagoveštava i finiju podelu na tri ere.
- Struktura je meka. DBSCAN pokazuje da tim-sezone čine jedan gust kontinuum bez gustinski razdvojenih grupa, pa su umerene siluete particionih metoda (oko 0,2 do 0,3) realna slika podataka, a ne slabost algoritama. Isto potvrđuju HDBSCAN, OPTICS i CLIQUE, koji se razlikuju samo po tome koliko razređenih ivica proglaše šumom, od 0,5% do 87,8%.
- Redukcija atributa pomaže. Ručno izabran skup od 10 pokazatelja efikasnosti daje najbolje vrednosti svih metrika (silueta do 0,3005, DB 1,4089), bolje i od svih 38 atributa i od PCA redukcije. Pažljiv izbor atributa vredi više od gomilanja svih dostupnih.
- Metrike treba tumačiti kritički. Degenerisane podele (single, complete i average veza, kao i sitni udaljeni DBSCAN klaster) dobijaju veštački visoke siluete. Provera veličine najmanjeg klastera pokazala se ključnom za pošteno poređenje.
- Igrači se dele po fizičkom tipu, duž ose bek-centar. Sva tri algoritma nezavisno biraju $k = 2$ sa istom interpretacijom. GMM dodatno kvantifikuje granične slučajeve verovatnoćama, a Spectral postiže najvišu siluetu (0,3127) izdvajanjem kompaktnije podgrupe.
- K-Means i Bisecting K-Means nezavisno biraju podelu na dva klastera i ostvaruju gotovo identične rezultate (Silhouette $\approx 0,297$), što ukazuje na stabilnu segmentaciju podataka. DBSCAN pronalazi sedam malih klastera, ali čak 92,9% objekata označava kao šum, uz znatno niži Silhouette koeficijent (0,1762), pa se pokazuje manje efikasnim za ovaj skup podataka.

Svi koraci, od automatskog preuzimanja podataka, preko preprocesiranja i vizuelizacije (PCA 2D i 3D, t-SNE), do treniranja, evaluacije i čuvanja modela, nalaze se u priloženom Jupyter notebook-u i mogu se ponoviti u lokalnom okruženju.